

## סיכום נוסחאות קורס אלגוריתמי ניווט ושערוך מיקום תשפ"ב

### מסנן היסטוגרמה

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \text{ הסתברות מותנית:}$$

$$P(H|E) = \frac{P(E|H) \cdot P(H)}{P(E)} \text{ חוק בייס:}$$

$$P(X, Y, Z) = P(X|Y, Z) \cdot P(Y|Z) \cdot P(Z) \text{ כלל השרשרת:}$$

$$P(H|E_1, E_2) = \frac{P(E_1|H, E_2) \cdot P(H|E_2)}{P(E_1|E_2)} \text{ חוק בייס עם שני evidences (הרחבה):}$$

$$P(B) = P(B|A) \cdot P(A) + P(B|\bar{A}) \cdot P(\bar{A}) \text{ חוק ההסתברות השלמה:}$$

$$P(B) = \sum_{A_i \in A} P(B|A_i)P(A_i) \text{ הרחבה ליותר משני מאורעות משלימים:}$$

אנטרופיה:  $H(X) = - \sum_x P(x) \cdot \log(P(x))$ , כאשר  $X$  הוא משתנה מקרי, ו- $x$  מסמל ערך אפשרי שלו.

$$P(X_t|Z_{1:t}, U_{1:t}, m) = P(X_t|X_{t-1}, Z_t, U_t, m) \text{ השערת (הנחת) מרקוב:}$$

### מסנן קלמן במימד אחד

$$0 \leq KG \leq 1, KG = \frac{E_{estimation}}{E_{estimation} + E_{measurement}} = \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} \text{ kalman gain (מעין ממוצע משוקלל):}$$

$$Est_t = Est_{t-1} + KG[Meas_t - Est_{t-1}] \text{ שערוך בזמן } t \text{ (נוסחה לחישוב):}$$

$$E_{est_t} = \sigma_{est_t}^2 \text{ כאשר } E_{est_t} = [1 - KG](E_{est_{t-1}}) \text{ הטעות במדידה בזמן } t:$$

$$N(\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} \text{ פונקציית ה-PDF של התפלגות גאוסיאנית:}$$

הכפלת גאוסיאנים  $(\mu_1, \sigma_1)$  עם  $(\mu_2, \sigma_2)$ : נותנת התפלגות גאוסיאנית חדשה עם הפרמטרים

$$\mu_3 = \frac{\mu_1 \cdot \sigma_2^2 + \mu_2 \cdot \sigma_1^2}{\sigma_1^2 + \sigma_2^2}, \sigma_3^2 = \frac{1}{\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}}$$

$$\mu_3 = \mu_1 + KG(\mu_1 - \mu_2), \sigma_3^2 = \sigma_1^2 - KG \cdot \sigma_1^2 \text{ דרך שקולה:}$$

חיבור גאוסיאנים (קונבולוציה - תנועה במסנן קלמן): תזוזה של  $\mu_2$  עם חוסר ודאות  $\sigma_2$  כאשר המיקום הנוכחי

$$\mu_3 = \mu_1 + \mu_2 \text{ ו- } \sigma_3^2 = \sigma_1^2 + \sigma_2^2 \text{ מתואר ע"י } \mu_1, \sigma_1 \text{ תתן התפלגות גאוסית עם}$$

## מסנן קלמן בכמה מימדים

משוואות התנועה עם מהירות קבועה:  $s = v \cdot t$ , או  $X_t = X_0 + \Delta t \cdot v$

משוואות התנועה עם תאוצה קבועה:  $a_t = a_o$

$$V_t = \int_0^t a(t) dt = a_o \cdot \Delta t + V_0$$

$$X_t = \int_0^t V(t) dt = V_0 \cdot \Delta t + \frac{1}{2} \cdot a_o \cdot \Delta t^2 + X_0$$

• אצלנו  $X_0 = X_{t-1}$  ואז  $\Delta t$  יהיה השינוי בזמן מהמדידה האחרונה.

נוסחת חישוב ה-variance של משתנה:  $\sigma_x^2 = \frac{\sum_{i=1}^N (\bar{x} - x_i)^2}{N}$  כאשר  $\sigma_x$  היא השונות של  $X$ .

נוסחת ה-covariance בין שני משתנים:  $\sigma_x \sigma_y = \frac{\sum_{i=1}^N (\bar{x} - x_i)(\bar{y} - y_i)}{N}$

• ככל שהערך המוחלט של ה-cov גדול יותר, המשתנים קשורים יותר, וככל שהוא קטן יותר - להפך.

מטריצת ה-variance-covariance בשני מימדים:  $P = \begin{bmatrix} \sigma_x^2 & \sigma_x \sigma_y \\ \sigma_y \sigma_x & \sigma_y^2 \end{bmatrix}$

• מטריצה ריבועית וסימטרית.

• האלכסון הראשי מתאר את השונות של המשתנים, והאלכסון המשני מתאר את הקורלציה ביניהם.

וקטור המצב ומטריצת חוסר הודאות של מערכת בשני מימדים:  $\Sigma = \begin{bmatrix} \sigma_x^2 & 0 \\ 0 & \sigma_y^2 \end{bmatrix}$   $\mu = \begin{bmatrix} X \\ Y \end{bmatrix}$

בכמה מימדים:  $\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_1 \sigma_2 & \sigma_1 \sigma_3 & \dots & \sigma_1 \sigma_n \\ \sigma_2 \sigma_1 & \sigma_2^2 & \sigma_2 \sigma_3 & \dots & \sigma_2 \sigma_n \\ \sigma_3 \sigma_1 & \sigma_2 \sigma_3 & \sigma_3^2 & \dots & \sigma_3 \sigma_n \\ \dots & \dots & \dots & \dots & \dots \\ \sigma_n \sigma_1 & \dots & \dots & \dots & \sigma_n^2 \end{bmatrix}$   $\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \dots \\ \mu_n \end{bmatrix}$

•  $\Sigma$  מתארת את חוסר הודאות במערכת. בתחילת השאלה כל האיברים שהם לא באלכסון הראשי  $= 0$ , כי מניחים שאין קשר בין המשתנים, כלומר הם ב"ת.

שלב ה-prediction:

מהירות קבועה:

מטריצת  $F$  (מתארת את המודל הדינאמי של המערכת) כאשר וקטור המצב הוא  $\begin{bmatrix} P \\ V \end{bmatrix}$ :  $F = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}$

• אם הפרש הזמנים בין מדידה למדידה משתנה, כל פעם נשנה את  $\Delta t$  למשהו אחר.

אם וקטור המצב מכיל מידע על שני מימדים:  $\begin{bmatrix} P_x \\ P_y \\ V_x \\ V_y \end{bmatrix}$  אז מטריצת  $F$  תהיה  $F = \begin{bmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$

$$\begin{aligned} \text{עדכון וקטור המצב: } \begin{bmatrix} P \\ V \end{bmatrix}_{k+1} &= \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} P \\ V \end{bmatrix}_k \\ X_{k+1} &= F \cdot X_k \text{ , כלומר} \\ P_{k+1} &= F \cdot P_k \cdot F^T \\ \text{עדכון מטריצת } P: & \\ P_{k+1} &= F \cdot P_k \cdot F^T + Q \text{ אם מוסיפים גם חוסר ודאות בתזוזה:} \end{aligned}$$

$$\begin{aligned} \text{במקרה שיש שינויים נוספים במערכת:} \\ \text{עדכון וקטור המצב: } \begin{bmatrix} P \\ V \end{bmatrix}_{k+1} &= \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} P \\ V \end{bmatrix}_k + Bu \\ B &= \text{מטריצת הבקרה ו-} u = \text{וקטור הבקרה.} \\ \begin{bmatrix} P \\ V \end{bmatrix}_{k+1} &= \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} P \\ V \end{bmatrix}_k + \begin{bmatrix} \frac{1}{2} \Delta t^2 \\ \Delta t \end{bmatrix} \cdot a_o \\ \text{למשל במקרה של תאוצה קבועה ותנועה במימד אחד:} \end{aligned}$$

$$B = \begin{bmatrix} \frac{\Delta t^2}{2} & 0 \\ 0 & \frac{\Delta t^2}{2} \\ \Delta t & 0 \\ 0 & \Delta t \end{bmatrix}, u = \begin{bmatrix} a_x \\ a_y \end{bmatrix}$$

תנועה בדו מימד ותאוצה קבועה בכל ציר:  
המרה ממרחב המצב למרחב החישה:  $\mu_{expected} = H_k \cdot X_k$   
 $\Sigma_{expected} = H_k \cdot P_k \cdot H_k^T$   
כאשר  $H$  היא מטריצת ההמרה (ממירה את וקטור המצב ממרחב המצב למרחב החישה). אם היא שווה למטריצת היחידה, המרחבים זהים (יש חישה עבור כל אחד מהמשתנים בוקטור המצב).

שלב ה-measurement:  
 $Z_k =$  וקטור המדידה (במרחב החישה),  $R_k =$  מטריצת הרעש במדידה (גם כאן מניחים שהקורולציות = 0).

איחוד בין התוצאות (שקול להכפלת גאוסיאנים במימד אחד) כאשר  $0 =$  השערוך,  $1 =$  המדידה:

$$\begin{aligned} \text{kalman gain (מטריצה): } KG &= \Sigma_1 (\Sigma_1 + \Sigma_2)^{-1} \\ \text{וקטור המצב החדש: } \mu' &= \mu_1 + KG(\mu_2 - \mu_1) \\ \text{מטריצת חוסר הוודאות החדשה: } \Sigma' &= \Sigma_1 - KG \cdot \Sigma_1 \\ \text{המרה ממרחב החישה למרחב המצב: } KG &= P_k \cdot H_k^T (H_k P_k H_k^T + R_k)^{-1} \\ X_k' &= X_k + KG(Z_k - H_k X_k) \\ P_k' &= P_k - KG \cdot H_k \cdot P_k \end{aligned}$$

## מסנן קלמן מורחב (EKF)

חישה LIDAR - חישוב המרחק בין הרובוט לבין האובייקט:  $R = \frac{c \cdot t}{2}$ , כאשר  $c$  היא מהירות האור,  $t$  הוא הזמן שלקח לקרן הלייזר לחזור חזרה אלינו.

$$\begin{aligned} R = \text{range} &= \sqrt{x^2 + y^2 + z^2} \\ \phi = \text{elevation} &= \text{tg}^{-1} \frac{y}{x} \end{aligned}$$

$$\theta = azimuth = \cos^{-1} \frac{z}{\sqrt{x^2+y^2+z^2}} = \frac{R}{\sqrt{x^2+y^2+z^2}}$$

פיתוח טיילור (קירוב פונקציה לטור פולינומים אינסופי):  $f(x) = \sum_{i=0}^{\infty} a_i x^i = a_0 + a_1 x + a_2 x^2 + a_3 x^3 + \dots$

כאשר מפתחים סביב נקודה  $a$ :  $f(x) = f(a) + f'(a)(x - a)$  בד"כ  $\mu = a$  כי שם יש הכי הרבה דגימות.

הרחבה:  $h(x) = h(\mu) + \frac{\partial h(\mu)}{\partial x} (x - \mu)$

$$H_j = \begin{bmatrix} \frac{\partial h_1}{\partial x_1} & \frac{\partial h_1}{\partial x_2} & \dots & \frac{\partial h_1}{\partial x_n} \\ \frac{\partial h_2}{\partial x_1} & \frac{\partial h_2}{\partial x_2} & \dots & \frac{\partial h_2}{\partial x_n} \\ \dots & \dots & \dots & \dots \\ \frac{\partial h_n}{\partial x_1} & \frac{\partial h_n}{\partial x_2} & \dots & \frac{\partial h_n}{\partial x_n} \end{bmatrix}$$

מטריצת היעקוביאן: מטריצת מעבר בין וקטורים (שאינן ביניהם התמרה לינארית).

ניתן להשתמש בה למעבר ממרחב המצב ( $X$ ) למרחב החיפוש ( $Z$ ):  $Z = H_j \cdot X$  עבור חיישנים כמו LIDAR,

כאשר מגדירים את המשתנים של ה-LIDAR כ- $x$ ים ואת המשתנים של וקטור המצב כ- $y$ ים.

חיישן RADAR - העברה לקורדינטות במרחב:  $\rho = \sqrt{P_x^2 + P_y^2}$  (מרחק מהאובייקט)

$\phi = \tan^{-1}(P_y/P_x)$  (זווית לאובייקט)

$\dot{\rho} = \frac{P_x \dot{V}_x + P_y \dot{V}_y}{\sqrt{P_x^2 + P_y^2}}$  (מהירות רדיאלית)

שגיאת ה-RMSE:  $\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i^{Est} - x_i^{True})^2}$

## מסנן חלקיקים

התפלגויות לא פרמטריות: סט החלקיקים  $\chi = \{ \langle x_j, w_j \rangle \}_{j=1, \dots, J}$  ( $x$  = ההיפותזה,  $w$  = המשקל),

פונקציית הצפיפות  $p(x) = \sum_{j=1}^J w_j \delta_{x_j}(x)$  ( $\delta$  = 0 חוץ מ- $x$  בו היא שווה ל- $\infty$ ).

הגרלת חלקיקים:  $0 < x < x_{max}, 0 < y < y_{max}, 0 < \theta < 2\pi$

משוואות התנועה בהנחה ש- $\theta_f = \theta_0$ :  $x_f = x_0 + v \cdot \Delta t \cdot \cos(\theta_0)$

$y_f = y_0 + v \cdot \Delta t \cdot \sin(\theta_0)$

משוואות התנועה בהנחה ש- $\theta_f \neq \theta_0$ , כלומר  $\dot{\theta} \Delta t$ :  $\theta_f = \theta_0 + \dot{\theta} \Delta t$

$x_f = x_0 + \frac{v}{\dot{\theta}} (\sin(\theta_0 + \dot{\theta} \Delta t) - \sin(\theta_0))$

$y_f = y_0 + \frac{v}{\dot{\theta}} (\cos(\theta_0) - \cos(\theta_0 + \dot{\theta} \Delta t))$

$$\begin{bmatrix} x_m \\ y_m \\ 1 \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta & x_p \\ \sin \theta & \cos \theta & y_p \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_c \\ y_c \\ 1 \end{bmatrix} \quad \text{rotation matrix (התמרות הומוגניות):}$$

כאשר  $x_m, y_m$  הם הקורדינטות האמיתיות של ה-landmarks במרחב (במפה).

$x_c, y_c$  הם הקורדינטות של ה-landmark ביחס למיקום של החלקיק (כאילו החלקיק בראשית הצירים).

$x_p, y_p$  הם הקורדינטות האמיתיות של החלקיק במרחב (נתון).

$\theta$  היא הזווית של החלקיק.

bayesian weight function (פונקצית משקל עם זכרון שעוזרת לעבוד עם מספר קטן של חלקיקים):

$$weight(x_t^{[k]}) = k \cdot sense(x_t^{[k]}) + (1 - k) \cdot weight(x_{t-1}^{[k]})$$

חישוב השגיאה (עבור כל רכיב בוקטור, למשל  $x, y, \theta$ ):

$$MSE: \frac{\sum_{i=1}^M w_i \sqrt{(P_i - true)^2}}{\sum_{i=1}^M w_i}, \text{ או המרחק בערך מוחלט של החלקיק הטוב ביותר מהאמת: } |P_{best} - true|$$

## Controllers

smoothing algorithm - יש למזער את:  $(x_i + y_i)^2$  וגם את  $(y_i - y_{i+1})^2$

$(x_i + y_i)^2 + \alpha(y_i - y_{i+1})^2$  ככל ש- $\alpha$  גדל  $\leftarrow$  הדרך חלקה יותר,  $\alpha$  קטן  $\leftarrow$  הדרך קרובה למקורית.

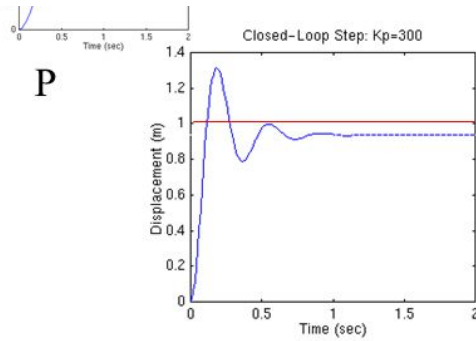
עם gradient descent העדכון הוא:  $y_i = y_i + \alpha(x_i - y_i)$  ו-  $y_i = y_i + \beta(y_{i-1} + y_{i+1} - 2y_i)$

בקר	נוסחה ל- $\alpha$ (זווית ההיגוי)	בעיה
P	$\alpha = -\tau_p \cdot CTE$	עושה overshoot, כלומר נדנודים כל הדרך על מנת לחזור למסלול
PD	$\alpha = -\tau_p \cdot CTE - \tau_D \frac{d}{dt} \cdot CTE$ $\frac{d}{dt} \cdot CTE = \frac{CTE_t - CTE_{t-1}}{\Delta t}$	אם יש נטייה בגלגלים לכיוון מסוים והם לא ממש ישרים, יכול לא להתכנס למסלול
PID	$\alpha = -\tau_p \cdot CTE - \tau_D \cdot \frac{d}{dt} CTE - \tau_I \cdot \sum CTE$ Proportional      Differential      Integral	


**רכיב P:** קובע את הזווית שצריך כדי להתקרב למסלול בצורה פרופורציונלית ל-CTE. ככל שהוא גדול יותר, התגובה חדה יותר ביחס לטעות ולכן במסלול יהיו "נדנודים" בקצב מהיר יותר.

**רכיב D:** הרכיב המרסן של P, אשר לוקח בחשבון את השינוי של ה-CTE לאורך זמן. בעצם כאשר הוא מזהה שהטעות קטנה עם הזמן, הוא גורם להגה להתיישר בצורה פרופורציונלית לשינוי ובכך מוריד את הנדנודים ויוצר דרך חלקה יותר, אבל יכולה להיות עדיין רחוקה מהמסלול אם יש נטייה בגלגלים. חשוב לציין כי רכיב זה

לא בהכרח מבטל את ה-overshoot, אלא רק את ה-marginal unstable (התנועה הסינוסית). הוא יכול לבטל את ה-overshoot אם נגדיל אותו מאוד ונקטין את  $\kappa$  מאוד.  
**רכיב I:** משנה את הזווית בהתאם לאינטגרל, כלומר לשטח שנמצא בין המכונית לבין המסלול. כך אם השטח גדול, נבין שצריך להתקרב למסלול.





P



PD

PI



PID

twiddle algorithm (אלגוריתם למציאת ה- $\kappa$ ים האופטימליים)